



Alfred
KINSEY

Ça,
c'est le célèbre
entomologiste





Au cours de sa carrière
Kinsey a amassé une collection
d'environ
5,5 millions
de **spécimens** de
mouches - à - galles.

Cette collection réside
aujourd'hui au musée
américain d'histoire
naturelle, à New-York.



La collection est incomplète
et désorganisée, car avant
d'avoir terminé sa recherche sur
les mouches-à-galles,

Kinsey s'est tourné
vers ...





... les comportements
sexuels de l'être
humain.



En 1948, puis en 1953, il publie deux volumes de la plus vaste enquête jamais menée jusqu'alors sur la sexualité humaine.

En tout, près de
11 300 personnes
ont participé.

D'après ces données,
Kinsey affirme
qu'il y aurait, parmi
la population,

environ **10%**
de personnes homosexuelles.



le 17 mai, c'est la

Journée internationale

contre l'homophobie,
la transphobie,
la biphobie...

contre l'intolérance envers la diversité sexuelle et de genre.

Is 10% of the population really gay?

Drawing on the widest survey of sexual behaviour since the Kinsey Report, David Spiegelhalter, in his book Sex By Numbers, answers key questions about our private lives. Here he reveals how Kinsey's contested claim that 10% of us are gay is actually close to the mark

David Spiegelhalter

Sun 5 Apr 2015 08.00 BST



974



Changing times: students stage a kiss-in at a Sainsbury's store in Brighton last year after two gay women were threatened with ejection for kissing. Photograph: Christopher Ison

Comment ?

Petit guide d'autodéfense statistique

une introduction simple
aux probabilités et aux statistiques.

Élise Davignon, M.Sc.

doctorante et chargée de cours à l'UdeMontréal


elise.davignon@umontreal.ca




A photograph of a park during autumn. The trees are heavily laden with red, orange, and yellow leaves. In the foreground, a woman in a blue plaid shirt and jeans stands facing away from the camera, looking towards the trees. To her right, a man sits on the grass under a large tree. The ground is covered with fallen leaves.

Apperçu des 4.) Statistiques


Que nous disent
vraiment les chiffres ?




L'échantillon.




C'est difficile
de demander à
tout le monde ...







... alors on prélève
un échantillon.

L'échantillon
est l'ensemble des individus
d'une population pour
lesquels on recueille
des données.







... alors on prélève
un échantillon.



on assume
implicitement
que l'échantillon et
la population ont
les mêmes propriétés
statistiques.



... alors on prélève
un échantillon.



on assume
implicitelement
que l'échantillon et
la population ont
les mêmes propriétés
statistiques.

Les données.



	Taille en cm.	Masse corporelle (kg.)
Robert	177 cm	70 kg
Paul	183 cm	86 kg
Marie	169 cm	61 kg

Une donnée est une mesure de la valeur d'une variable pour un individu connu de l'échantillon.


Les données.



	Taille en cm.	Masse corporelle (kg.)
Robert	177 cm	70 kg
Paul	183 cm	86 kg
Marie	169 cm	61 kg

Une donnée est une mesure de la **valeur** d'une **variable** pour un **individu** connu de l'échantillon.

Les données.



	Taille en cm.	Masse corporelle (kg.)
Robert	177 cm	70 kg
Paul	183 cm	86 kg
Marie	169 cm	61 kg

variables.

Une donnée est une mesure de la **valeur** d'une **variable** pour un **individu** connu de l'échantillon.

Les données.



	Taille en cm.	Masse corporelle (kg.)
Robert	177 cm	70 kg
données ←	183 cm	86 kg
Marie	169 cm	61 kg


Une donnée est une mesure de la **valeur** d'une **variable** pour un **individu** connu de l'échantillon.

Les données.



	T	M
₁	t_1	m_1
₂	t_2	m_2
₃	t_3	m_3

Une donnée est une mesure de la valeur d'une variable pour un individu connu de l'échantillon.



Les données.

$$T(\text{ }) = t_1 = 177 \text{ cm}$$



variable individu de l'échantillon

donnée (symbole)

donnée (valeur)

On utilise souvent des **lettres minuscules** pour les **données** pour les différencier des **variables**.

Les statistiques.





La masse totale


La hauteur totale

Une **statistique** est une quantité qui dépend des **données** d'un **échantillon**.

Les statistiques.




$m_{\text{tot.}}$



Une **statistique** est une quantité qui dépend des **données** d'un **échantillon**.

Les statistiques.



$$m_{\text{tot.}} \left(\begin{array}{c} \text{1} \\ \text{2} \\ \text{3} \end{array} \right) = m_1 + m_2 + m_3$$


↓
La statistique

$$= 217 \text{ kg.}$$

↓
l'échantillon

sa valeur.

On dit que la **statistique** est une fonction des données de l'échantillon.




① Des exemples.

$$\bar{x} = \frac{x_1 + x_2 + x_3 + \dots + x_n}{n}$$

La moyenne échantillonnale, ou simplement la « moyenne » est une statistique.



Remarquons que les statistiques peuvent aussi dépendre de la taille de l'échantillon (n).



Des exemples.

$$s^2 = \frac{(x_1 - \bar{x})^2 + (x_2 - \bar{x})^2 + \dots + (x_n - \bar{x})^2}{n-1}$$

La variance échantillonnale, et


$$s = \sqrt{s^2}$$

l'écart-type échantillonnel aussi.




L'inférence.


L'inférence



Ce qu'on
a:




Ce qu'on
veut:




des **données** d'un échantillon
pour diverses **variables**.

des informations sur la
distribution de ces **variables**
dans la **population**.

L'inférence




Ce qu'on
a:




comment on
l'obtient.

des **données** d'un échantillon
pour diverses **variables**.

des informations sur la
distribution de ces **variables**
dans la **population**.



Les données - modèle.



Le «vrai»
échantillon



t_1 m_1 ...

t_2 m_2 ...

t_3 m_3 ...


... ...

Les «vraies»
données.

T? M?

Hypothèses et suppositions
sur la **distribution** dans la
population.


T_1 M_1 ...
 T_2 M_2 ...
 T_3 M_3 ...
......



données - modèle.



Les données - modèle.




Les données - modèle sont des variables aléatoires qui simulent un jeu de données pour un échantillon aléatoire de taille égale à l'échantillon réel, conformément à nos hypothèses et nos suppositions.

T? M?


Hypothèses et suppositions sur la distribution dans la population.

T_1	M_1	...
T_2	M_2	...
T_3	M_3	...
...



données - modèle.

Les données - modèle.



$t_1 \ m_1 \ \dots$

$t_2 \ m_2 \ \dots$

$t_3 \ m_3 \ \dots$

$\dots \ \dots$

$\bar{t} \ \bar{m}$

$s_t \ s_m$

Les statistiques
échantillonnelles



$T_1 \ M_1 \ \dots$
 $T_2 \ M_2 \ \dots$
 $T_3 \ M_3 \ \dots$
 $\dots \ \dots$

$\bar{T} \ \bar{M}$

$s_T \ s_M$


Les statistiques -
modèle.

Les données - modèle.



en comparant les statistiques échantillonnelles aux distributions prévues des statistiques - modèle ...

Les données - modèle.





... On peut tester
notre modèle.



L'inférence paramétrique.



L'inférence paramétrique.



On assume que X suit une certaine distribution.



On cherche alors à connaître la valeur de paramètres.

L'inférence paramétrique.




On assume que X suit une certaine distribution.
On cherche alors à connaître la valeur de paramètres.

L'inférence paramétrique.




On assume que X suit une certaine distribution.
On cherche alors à connaître la valeur de paramètres.

Les estimateurs.



Avec seulement ces données, ($n=20$)
quel serait un bon estimé
de l'étendue de la distribution de X ?

Les estimateurs.





Rappel: L'étendue est la largeur de la plage de valeurs possibles.

($n=20$)


Avec seulement ces données,
de quel serait un bon estimé
l'étendue de la distribution de X ?

Les estimateurs.




$$\begin{aligned}\max - \min &= 5,1 - 1,2 \\ &= 3,9.\end{aligned}$$

Serait un bon estimé.





Les estimateurs.



$$(\max - \min) \times \frac{n+1}{n} = 3,9 \times \frac{21}{20} = 4,05$$



Serait en fait marginalement meilleur !
(surtout lorsque n est relativement petit)

Les estimateurs.



Un **estimateur** d'un **paramètre** est une **statistique** de l'**échantillon** qui a la propriété d'être une meilleure **approximation** du **paramètre** plus l'**échantillon** est grand. ($n \rightarrow \infty$)

Les estimateurs.



Un **estimateur** d'un **paramètre** est une **statistique** de l'**échantillon** qui a la propriété d'être une meilleure **approximation** du **paramètre** plus l'**échantillon** est grand. ($n \rightarrow \infty$)

Les estimateurs.



$$\bar{x} \xrightarrow{n \rightarrow \infty} E(X)$$

La moyenne échantillonnale
est un estimateur
de l'espérance

$$s \xrightarrow{n \rightarrow \infty} \sigma(X)$$

L'écart-type échantillonnel
est un estimateur
de l'écart-type


$$s^2 \xrightarrow{n \rightarrow \infty} \text{Var}(X)$$

La variance échantillonnale
est un estimateur
de la variance


$$\hat{\lambda} \xrightarrow{n \rightarrow \infty} \lambda(X)$$

On utilise souvent
le $\hat{\lambda}$ pour
les estimateurs.

Les intervalles de confiance.




Les intervalles de confiance.




On cherche un intervalle I t.q.

$$P(\hat{\lambda} \in I) = 1 - \alpha$$





Les intervalles de confiance.





Plus α est petit,
plus on a confiance,
mais plus l'intervalle est large.

Les intervalles de confiance.



Les intervalles de confiance.





19 fois sur 20 !



L'inférence **non-paramétrique**
et les **tests d'hypothèse**.

L'hypothèse nulle.




“l'hippopo-thèse”

$$\mathcal{H}_0$$

Il s'agit d'une hypothèse à tester concernant la **distribution** de **variables** dans la population.

ex: $X \perp Y$ $X \sim \mathcal{N}$
 X et Y sont indépendantes X est de loi normale.
etc.

Le test



On sélectionne une
statistique de test

On la compare à la **distribution**
prédictive pour la **statistique -**
modèle en supposant que


\mathcal{H}_c
est vraie.



L'échec.



On **rejette** l'hypothèse
si la valeur de la **statistique**
de test est **trop improbable**
pour la **statistique-modèle**.





L'échec.




Le seuil de signification

α est la probabilité d'échouer
le test si H_0 est vraie:

$$\alpha = P(\textcircled{F} \mid H_0)$$

plus α est petit, plus un échec
au test est significatif.



L'échec.



La valeur P

est la probabilité que la **statistique-modèle** soit au moins aussi improbable que la **statistique de test**.

$$P = P(\hat{\lambda} \text{ «piègue» } \hat{\lambda} | H_0)$$

plus P est petit, plus on risque d'échouer.



l'échec.




Donc, le test échoue
et l'hypothèse est rejetée
si

$$P < \alpha.$$

Le non-échec.



Si le test n'échoue pas,
on ne peut pas
conclure que H_0 est
vraie. On ne peut
rien conclure.



Merci
pour votre attention!



Voici l'éclipse de
la nuit du 15 au 16
mai 2022.



Cette photo
n'a pas rapport
elle est juste
belle.



